



12차시 · 내가 강해지는 게 두려워

강력한 AI 안전장치 카드

카드를 잘라 모듈별로 나눕니다. 애매한 카드는 가운데 두고 이유를 말합니다. 정답보다 기준을 만드는 것이 목표입니다.

멈춤 버튼이 있다

한 사람이 혼자 통제한다

여러 사람이 검증한다

AI가 자기 목표를 스스로 바꾼다

위험하면 작동을 멈춘다

결정 이유를 사람이 확인할 수 있다

우리 모듈 기준

우리는 _____라고 생각한다. 왜냐하면 _____이기 때문이다.